

第四章 基于金字塔与代理中介注意力的尺度解耦蒸馏方法研究

4.1 引言

随着视觉任务复杂度的不断提升，传统基于全局特征或全局 logits 的知识蒸馏方法在多目标场景与细粒度分类任务中逐渐暴露出性能瓶颈^[73]。全局平均池化在压缩空间维度的同时，不可避免地混合了来自不同空间区域的语义信息，使教师模型在输出端所蕴含的判别知识难以精确对应到具体目标或局部结构上，从而限制了学生模型对复杂视觉场景的细粒度理解能力。

为缓解上述问题，近年来研究者开始从空间结构层面对蒸馏过程进行重构，其中尺度解耦蒸馏 SDD 作为代表性工作，通过在不同空间尺度上对特征图进行局部划分并施加独立监督，使蒸馏过程由“全局粗粒度对齐”转向“多尺度细粒度约束”^[73]。该思想在一定程度上缓解了全局 logits 蒸馏中常见的语义混叠问题，使学生模型能够在不同尺度下感知更具判别性的局部线索，因而在细粒度识别与复杂背景场景中展现出较大的应用潜力。

然而，尺度解耦蒸馏并非简单地引入多尺度监督即可充分释放其优势，其在结构设计层面仍然存在不可忽视的局限性。首先，SDD 依赖于固定规则的空间网格划分来构建局部监督单元，但现实视觉场景中的目标形态往往具有显著的非机械特征，这种机械式的网格划分极易将语义完整的目标切割至多个网格区域，或将背景噪声与前景目标混合在同一局部单元中，从而削弱局部 logits 的语义纯度^[94]。其次，SDD 在不同尺度上的蒸馏损失通常是相互独立计算并简单加权求和的，这种“尺度并列”的优化方式在物理上切断了不同尺度特征之间的信息流动，使深层特征中高度抽象的语义难以有效指导浅层特征的局部判别，进而在尺度之间形成语义孤岛，限制了模型对多尺度目标的整体建模能力^[95]。

这就容易导致图 4.1 所示的局部突出问题，即由于机械地局部解耦导致将全鱼图像识别为鱼尾。当模型仅在不同尺度的局部网格上独立进行蒸馏监督时，局部判别性较强的区域可能在某一尺度上被过度放大，而缺乏来自其他尺度及全局语义的校正，从而主导最终的分类决策，导致整体语义层面的误判。更为关键的是，尺度解耦操作在提升局部判别能力的同时，也在空间维度上引入了结构性的语义割裂，由于不同网格区域在蒸馏过程中彼此独立，模型难以利用跨区域的全局上下文信息对局部预测结果进行统一约束，使“局部最优而整体不一致”的问题难以避免。




图 4.1 SDD 尺度解耦蒸馏的机械解耦导致的问题

综合来看，现有尺度解耦蒸馏方法在“局部判别增强”与“全局语义保持”之间仍然存在显著张力，这一结构性矛盾正是限制其性能进一步提升的核心瓶颈。这表明，有必要在保留局部细粒度监督优势的同时，引入能够恢复跨尺度与跨区域语义关联的增强机制，从而在结构层面重新平衡局部判别与全局一致性。

基于上述分析，本章提出了一种基于金字塔融合与代理中介注意力的尺度解耦蒸馏方法 PAMA-SDD。主要工作概括如下：

(1) 提出**渐进式金字塔融合模块 APF**。针对传统尺度解耦蒸馏中多尺度特征并列建模、尺度间缺乏信息交互的问题，本章在蒸馏流程前端引入渐进式金字塔融合策略，通过相邻尺度之间的逐级融合与自适应空间加权机制，构建语义连续、层级一致的多尺度特征表示，为后续尺度解耦蒸馏提供稳定且可蒸馏的高质量特征基础。

(2) 提出代理中介注意力模块 AMA 以恢复全局语义依赖。针对尺度解耦过程中局部划分导致的长距离依赖断裂问题，本章引入代理中介注意力机制，通过少量代理令牌作为全局语义中介，在保持线性计算复杂度的前提下高效建模跨区域语义关系，使局部特征的判别学习始终受到全局语义约束，从而有效缓解语义割裂现象。

(3) 设计全局代理一致性损失 GAC Loss 以显式约束全局语义对齐。在 AMA 的基础上，本章进一步在代理令牌层面引入全局一致性约束，从优化目标层面对师生模型的全局语义表示进行显式对齐，确保学生模型在接受局部解耦蒸馏监督的同时保持整体语义结构的一致性，从而实现局部判别增强与全局语义保持的协同优化。

(4) 构建端到端的 PAMA-SDD 蒸馏框架并进行系统性实验验证。本章将 APF、AMA 及 GAC Loss 有机整合，构建了完整的端到端尺度解耦蒸馏框架，并在 CIFAR-100、ImageNet 以及 CUB-200 等基准数据集上开展了大量实验验证。实验结果表明，PAMA-SDD 在同构与异构

4.2 PAMA-SDD 方法

为了克服上述局限，本章提出了一种如图 4.2 所示增强型的蒸馏框架——基于金字塔与代理中介注意力的尺度解耦蒸馏 PAMA-SDD。该框架构建了一个“多尺度构建—全局信息注入—细粒度解耦”的有机闭环系统。

图 4.2 PAMA-SDD 整体架构图

尽管 SDD 通过引入多尺度网格（如 1×1 , 2×2 , 4×4 ）缓解了语义混淆，但其在尺度维度的处理上存在本质的逻辑缺陷。具体而言，SDD 仅仅是在不同的网格粒度上分别计算损失并进行

加权求和，这种“多尺度并列统计”的方式切断了尺度间的信息流动。深层的高语义特征无法指导浅层的细节特征，导致各个尺度形成了孤立的“信息孤岛”，模型虽然看了很多个尺度，却未能形成一个统一的、层次化的视觉认知。

为缓解尺度解耦蒸馏 SDD 框架中仅依赖单一高层特征所带来的多尺度语义缺失问题，本章在蒸馏流程前端引入了一种渐进式金字塔融合模块 APF，用于构建语义对齐且细节充分的多尺度特征基础。不同于传统特征金字塔网络通过跨层直接连接实现多尺度融合的方式，APF 采用由浅入深的渐进式融合策略，使语义信息在相邻尺度间逐级传递，从而有效避免非相邻层特征直接交互所导致的语义鸿沟问题。通过自顶向下的路径，将深层特征 (F_{high}) 中高度抽象的类别语义逐层注入到浅层特征 (F_{low}) 中。

为进一步说明渐进式金字塔融合模块在整体框架中的结构设计与信息流动方式，表 4.2 给出了 APF 模块的整体结构示意图。




图 4.3 APF 模块结构示意图

如图 4.3 所示，APF 沿特征金字塔自底向上构建了一条连续的渐进式融合路径，在每一阶段仅对当前尺度特征与其相邻的深层特征进行对齐与融合，从而显式避免了非相邻尺度之间的直接交互。通过这种逐级注入的方式，深层语义信息得以平滑地传递至高分辨率特征中，而浅层特征中的空间细节也能够融合过程中得到有效保留。该结构为后续的自适应空间融合与尺度解耦蒸馏提供了稳定且一致的多尺度语义基础。

4.2.1.1 自适应空间融合机制

在具体实现上，APF 以相邻尺度特征为基本融合单元。设待融合的两层特征分别为 $X \in \mathbb{R}^{C \times H \times W}$ （浅层、高分辨率特征）与 $Y \in \mathbb{R}^{C \times H \times W}$ （经上采样后的深层、低分辨率特征）。

其中，浅层特征通常包含丰富的几何边缘与局部细节，而深层特征则更侧重于语义类别与

区域一致性。在低层阶段，APF 首先对浅层高分辨率特征进行初步融合，为后续尺度扩展提供稳定的局部细节基础；在中层与高层阶段，模块在保持空间分辨率对齐的前提下，逐级引入更深层特征，使融合特征在保留细粒度结构信息的同时逐步增强语义表达能力。通过这种渐进式设计，APF 能够在多尺度之间建立平滑、连续的语义过渡关系，从结构层面提升特征表示的一致性与鲁棒性。

考虑到浅层与深层特征在空间位置上的语义可信度存在明显差异，在各阶段的特征融合过程中，本章并未采用简单的逐元素相加策略，而是引入了一种自适应空间融合机制（Adaptive Spatial Fusion, ASF）作为 APF 的内部融合单元。如图 4.3 所示，该机制通过为不同尺度特征分支生成逐像素的融合权重，有效抑制了多尺度特征在空间位置上可能存在的冲突信息，使融合过程能够根据局部语义内容自适应地选择更具判别力的特征来源。ASF 的引入并非作为独立模块使用，而是服务于 APF 的渐进式融合目标，从而在保证多尺度语义一致性的同时，进一步提升融合特征的稳定性与判别性。

具体而言，首先将 X 与 Y 在通道维度进行拼接，并通过一个轻量级卷积层生成空间权重图 M ，公式如下：

$$M = \sigma(\text{Conv}(\text{Concat}(X, Y))), \quad (4.1)$$

其中， $\sigma(\cdot)$ 表示 Sigmoid 激活函数。该权重图刻画了在每一个空间位置上，浅层特征与深层特征的相对重要性。

最终的融合特征 F_{out} 定义如下：

$$F_{out} = X \odot M + Y \odot (1 - M), \quad (4.2)$$

其中 $\odot$ 表示逐元素相乘。需要指出的是，本章采用 Sigmoid 激活而非 Softmax 的原因在于，APF 的目标并非在多个分支间进行竞争式选择，而是对浅层与深层特征进行互补式加权融合。通过约束 $M \in [0, 1]$ 且权重和为 1，融合过程在数值上保持能量守恒，从而避免因权重失衡而引入额外的特征放大或抑制效应。

通过 APF 的渐进式融合与自适应空间调控，最终得到一组语义对齐、尺度一致且细节丰富的多尺度特征表示。该特征集作为后续尺度解耦蒸馏与代理中介注意力模块的输入基础，为学生模型提供了高质量的多尺度语义基座，从而为后续蒸馏过程的有效实施奠定了坚实基础。

4.2.1.2 渐进式金字塔融合路径

与一次性跨层融合不同，APF 在整个特征金字塔中以相邻尺度为单位逐级应用。如图 4.3 所示，具体而言，APF 沿着特征金字塔自底向上构建一条连续的融合路径，在每一层仅对当前尺度与其相邻的深层特征进行融合。通过这种渐进式策略，深层语义得以逐步注入高分辨率特

征中，而非通过一次性映射完成，从结构上避免了语义突变与信息失配。

这种设计使得多尺度特征在进入 SDD 解耦操作之前，已经完成了跨层语义校正与空间结构对齐，从而显著提升了多尺度表示的一致性与稳定性。

在 PAMA-SDD 框架中，APF 被置于骨干网络输出之后、尺度解耦蒸馏操作之前，其角色已超越传统意义上的特征增强模块。其意义在于：为 SDD 构建一个“可蒸馏的多尺度语义基座”。

在引入 APF 后，SDD 的每一次尺度解耦操作不再直接作用于语义层级割裂、尺度间彼此孤立的原始特征，而是基于已经完成跨尺度语义对齐、且具备稳定空间结构的高质量表示进行。这不仅从根本上缓解了固定网格划分带来的语义噪声问题，也为后续代理中介注意力模块建模全局上下文提供了可靠且一致的输入基础，从而显著提升了尺度解耦蒸馏的整体上限。

综上所述，APF 通过渐进式跨层融合与自适应空间加权机制，在不引入显著计算开销的前提下，有效弥合了深浅层特征间的语义鸿沟，为 PAMA-SDD 框架实现“局部解耦而不语义割裂”的蒸馏目标奠定了坚实基础。

4.2.2 代理中介注意力模块 AMA 的设计

尺度解耦蒸馏 SDD 通过在不同空间尺度上对特征图进行局部划分与独立监督，有效缓解了全局 logits 蒸馏中常见的语义混叠问题。然而，这种以网格为单位的局部解耦机制在提升细粒度判别能力的同时，也在结构层面引入了一种不可忽视的副作用：局部划分在物理上切断了特征图中不同空间位置之间的长距离依赖关系。这使得模型难以利用全局上下文对局部预测结果进行统一校正，从而限制了学生模型对复杂场景整体语义结构的理解能力。

需要指出的是，上述问题并非源于学生模型容量不足或蒸馏监督信号不充分，而是尺度解耦策略本身所引入的结构性局部性约束。因此，在保留 SDD 局部判别优势的前提下，引入一种高效、可控且适配蒸馏任务的全局语义建模机制，是提升尺度解耦蒸馏性能的关键。

自注意力机制通过显式建模特征图中任意位置之间的关系，已被广泛用于捕获长距离依赖。然而，将标准自注意力直接引入 SDD 蒸馏框架并不理想：其在空间维度上的平方级计算复杂度难以适应多尺度蒸馏场景^[96]，同时全连接式的像素建模方式也与卷积特征所固有的局部连续性与层级语义结构并不完全匹配。更重要的是，蒸馏任务的目标在于传递教师模型所蕴含的全局语义组织方式，而非穷举像素级两两依赖关系，这使得标准自注意力在蒸馏场景中存在明显的过度建模问题。

基于上述分析，本章认为蒸馏场景下的全局建模应侧重于语义层面的关系摘要，而非像素级的全连接依赖。基于这一设计原则，本章提出代理中介注意力模块 AMA，用于在计算复杂度可控的前提下，有效恢复尺度解耦蒸馏中的全局语义依赖。




图 4.4 标准自注意力和代理中介注意力计算复杂度对比示意图

为直观说明代理中介注意力与标准自注意力在建模方式与计算复杂度上的差异，图 4.4 给出了两种机制的对比示意。如图所示，标准自注意力通过显式计算所有像素对之间的相互关系实现全局信息交互，其计算复杂度随空间位置数呈平方级增长；相比之下，AMA 通过引入少量代理令牌（Agent Tokens）作为全局语义的中介节点，将全局建模过程分解为“代理聚合”和“代理广播”两个阶段，使像素级特征仅需与代理令牌进行交互，从而在保持语义完整性的同时显著降低计算复杂度^{[1][97]}。

在此基础上，为进一步说明代理中介注意力在蒸馏框架中的具体作用方式，图 4.5 给出了 AMA 在 PAMA-SDD 中的整体结构示意，AMA 模块在教师网络与学生网络中以对称方式部署，分别作用于经 APF 模块增强后的多尺度特征表示。通过池化与投影操作，特征图被映射为一组低维代理令牌，用于承载全局语义信息。随后，代理中介注意力在各自分支内完成像素特征与代理令牌之间的双向交互，从而生成全局增强的特征表示，并进一步送入后续的尺度解耦蒸馏阶段。需要强调的是，代理令牌在教师与学生分支中并不直接共享，而是通过全局代理一致性损失在语义层面进行约束，这使得学生模型在保持自身表征能力的同时，能够对齐教师模型的全局语义组织方式。

具体而言，设经 APF 模块处理后的特征表示为 $F \in \mathbb{R}^{C \times H \times W}$ ，本章引入一组可学习的代理令牌 $A \in \mathbb{R}^{N \times C}$ ，其中 $N \ll HW$ ，表示代理令牌的数量。AMA 的计算过程由两个相互协作的阶段构成。




图 4.5 AMA 模块结构流转示意图

在代理聚合阶段,特征图中的像素特征作为键和值,与代理令牌作为查询进行注意力计算,从而将分散于不同空间位置的全局信息汇聚至代理空间。通过该过程,每个代理令牌能够学习到对整幅特征图的语义摘要表示,形成对整体结构与上下文关系的集中建模。

在代理广播阶段,更新后的代理令牌作为键和值,像素特征作为查询再次进行注意力计算,将代理空间中建模的全局语义信息反馈至各空间位置,使局部特征在保持自身判别性的同时,能够受到全局语义结构的统一调控。

通过上述“像素—代理—像素”的两阶段交互机制,AMA 在不显式计算像素间两两关系的前提下,有效重建了尺度解耦蒸馏中的长距离依赖关系,其整体计算复杂度为 $O(NHW)$,在代理令牌数量固定的情况下,复杂度随特征图尺寸线性增长,适用于多尺度蒸馏场景。

需要强调的是,AMA 本身主要关注结构层面的全局依赖建模,并未在目标函数层面显式约束师生模型在全局语义空间中的一致性。为此,本章在 AMA 的基础上进一步引入全局代理一致性损失 GAC Loss,直接作用于代理令牌层面,对师生模型的全局语义表示进行显式对齐。二者相互配合,共同构成 PAMA-SDD 框架中恢复与约束全局语义结构的关键机制。

综上所述,代理中介注意力模块通过引入低维代理令牌,在保持线性复杂度的前提下有效重构了尺度解耦蒸馏中的全局语义依赖,为后续显式的一致性约束提供了稳定且可解释的全局表示基础。

4.2.3 全局代理一致性损失 GAC Loss 的设计

尽管代理中介注意力模块 AMA 能够在结构层面有效恢复尺度解耦蒸馏中的全局语义依赖,

但仅依赖特征增强本身，仍不足以保证师生模型在全局语义空间中的一致性。这是因为，在尺度解耦蒸馏框架中，师生网络分别通过各自的参数更新路径生成代理令牌，其语义表示仍可能因网络容量差异与优化目标不同而逐渐偏离。如果缺乏显式约束，代理令牌所承载的全局语义信息可能仅在各自模型内部自洽，而无法形成稳定、可迁移的共享语义结构。

从蒸馏的角度来看，AMA 更侧重于如何建模全局语义，而蒸馏过程本身还需要回答一个关键问题：学生模型是否真正继承了教师模型在全局语义层面的组织方式。为此，本章在 AMA 的基础上进一步引入全局代理一致性损失 GAC Loss，通过在代理令牌层面施加显式监督，约束师生模型对全局语义摘要的表征保持一致。

具体而言，GAC Loss 并不直接作用于像素级特征或局部解耦后的 logits，而是将代理令牌视为全局语义的“中介载体”，在更高层次上对齐师生模型的语义结构。由于代理令牌是在聚合整幅特征图信息的过程中形成的，其表示天然具备全局性与语义压缩特性，因此在该空间中施加一致性约束，能够有效避免像素级对齐所带来的噪声放大问题，同时更契合蒸馏任务“传递语义结构而非精确数值”的核心目标。

设教师模型与学生模型在 AMA 模块中得到的代理令牌分别如下：

$$A_t \in \mathbb{R}^{N \times C}, A_s \in \mathbb{R}^{N \times C}, \quad (4.3)$$

其中 N 表示代理令牌数量， C 为特征通道维度。GAC Loss 通过最小化师生代理令牌在语义空间中的差异，直接约束学生模型对教师全局语义摘要的模仿，其形式可表示为：

$$\mathcal{L}_{GAC} = \frac{1}{N} \sum_{i=1}^N \|A_s^{(i)} - A_t^{(i)}\|_2^2, \quad (4.4)$$

需要强调的是，这种一致性约束并非对代理令牌进行逐元素的僵硬匹配，而是在整体统计意义上引导学生模型学习教师模型所编码的全局语义结构。由于代理令牌本身已对空间信息进行了压缩与抽象，该损失在优化过程中具有良好的稳定性和可解释性。

从整体框架来看，AMA 与 GAC Loss 在功能上形成了清晰的分工与协同关系：AMA 负责在特征层面重构尺度解耦蒸馏中被削弱的全局依赖，为局部特征注入全局语义感知；而 GAC Loss 则在目标函数层面显式约束这种全局语义的一致性，防止其在师生网络中发生漂移。二者共同作用，使得 PAMA-SDD 不仅在结构上具备全局建模能力，同时在优化层面确保了全局语义知识能够被稳定、高效地迁移至学生模型。

综上所述，全局代理一致性损失通过在代理空间中建立直接、明确的蒸馏约束，补全了 AMA 在蒸馏目标层面的不足，使 PAMA-SDD 框架在“全局语义建模—语义对齐—知识迁移”三个环节上形成了完整闭环。

4.2.4 计算复杂度与参数开销分析

为保证所提出方法具备良好的工程可用性，本节对第四章蒸馏框架的训练阶段计算开销进行简要分析。需要说明的是，本文研究对象为知识蒸馏方法：额外模块仅在训练阶段用于构造蒸馏监督与特征交互，推理部署时仅保留学生网络，因此最终推理复杂度由学生模型本身决定。本节重点讨论训练阶段新增模块的计算量级与可控性。

(1) APF 模块的计算开销

设学生在第 l 个层级输出特征为 $F_l \in \mathbb{R}^{C_l \times H_l \times W_l}$ ，APF 通过自顶向下的渐进式融合路径将多层级特征逐级对齐与融合。该过程主要由 (i) 上采样/尺度对齐、(ii) 轻量卷积映射（如 1×1 或 3×3 ）以及 (iii) 逐元素融合组成。对任一层级而言，逐元素融合与上采样的复杂度均与特征元素数量线性相关，为 $O(C_l H_l W_l)$ ；若采用 $k \times k$ 卷积映射，其主要计算量为 $O(k^2 C_l H_l W_l)$ 。因此，APF 跨 L 个层级的总体复杂度可写为下式

$$O\left(\sum_{l=1}^L k^2 C_l H_l W_l\right) \quad (4.5)$$

即对参与融合的各层级呈线性叠加，且可通过减少融合层级数或选择轻量卷积核进一步控制开销。

(2) AMA 模块的计算开销

设特征图被展平成 $N = HW$ 个空间 token，每个 token 维度为 d 。标准自注意力的计算复杂度通常为 $O(N^2 d)$ ，当 N 较大时会带来明显开销。AMA 通过引入 M 个代理 token（ $M \ll N$ ）作为中介来重构长距离依赖，使注意力计算从“token-token 全连接”转化为“token-agent 与 agent-token”两阶段交互，从而将计算量降为线性量级，公式如下

$$O(Md) \quad (4.6)$$

相比于在 N 个空间 token 上直接施加全局一致性约束，GAC Loss 在代理层面进行对齐能够以更低的成本提供稳定的全局语义监督，从而弥补尺度解耦带来的视野缺陷。

4.2.5 优化目标与损失函数

综上所述，PAMA-SDD 框架通过联合优化任务损失、改进的局部解耦蒸馏损失以及全局代理一致性损失，对学生网络进行端到端训练，其整体优化目标可表示为：

$$\mathcal{L}_{Total} = \underbrace{\mathcal{L}_{CE}(z^S, y)}_{\text{任务损失}} + \alpha \sum_{l=1}^L \underbrace{\mathcal{L}_{PAMA}(f_l^S, f_l^T)}_{\text{局部解耦蒸馏}} + \beta \sum_{l=1}^L \underbrace{\mathcal{L}_{GAC}(A_l'^S, A_l'^T)}_{\text{全局语义对齐}} \quad (4.7)$$

任务损失 $\mathcal{L}_{CE}$ 作为监督学习的基本约束，直接作用于学生网络的分类输出，用于保证学生模型具备正确的判别能力与收敛方向。在蒸馏训练过程中，该损失为学生模型提供了稳定的优

化锚点，防止模型在过度拟合教师中间表示时偏离真实标签分布，是整个训练过程的基础性约束。

局部解耦蒸馏损失 $\mathcal{L}_{PAMA}$ 是 PAMA-SDD 框架中实现细粒度知识迁移的核心组成部分。该损失在不同尺度下对特征图进行局部划分，并在对应的网格区域内对齐师生模型的特征 logit，从而引导学生模型学习教师在局部区域中的判别模式。不同于全局特征或 logits 层面的蒸馏方式，局部解耦蒸馏能够显式关注目标内部及其局部上下文关系，在复杂场景与细粒度任务中具有更强的表达能力。在引入 APF 与 AMA 后，局部解耦蒸馏不再作用于语义割裂、尺度孤立的原始特征，而是建立在已经完成跨尺度语义对齐与全局语义增强的高质量特征表示之上，从而显著提升了局部监督的可靠性与有效性。

全局代理一致性损失 $\mathcal{L}_{GAC}$ 则从优化目标层面对全局语义建模进行显式约束。通过在代理令牌层面对齐师生模型的全局语义摘要，该损失确保学生模型在接受局部解耦蒸馏监督的同时，不会因局部最优而破坏整体语义结构，从而有效缓解尺度解耦过程中潜在的语义漂移问题。

需要强调的是，PAMA-SDD 的各组成模块结构与功能层面形成了紧密耦合的整体。首先，APF 为整个框架构建了语义连续且层级一致的多尺度特征金字塔，使尺度解耦蒸馏能够在不同分辨率下稳定地实施细粒度监督，从而有效缓解了传统方法在单一尺度下视野受限的问题；在此基础上，AMA 通过代理中介机制为局部特征引入全局语义上下文，使 SDD 的解耦操作由单纯的空间划分转变为受全局语义约束的局部聚焦过程，显著降低了语义割裂风险；最后，GAC Loss 以代理令牌为对齐载体，将原本隐式的全局特征增强转化为显式的全局语义一致性监督，从而在优化目标层面闭环了整个知识迁移过程，有效提升了师生网络间语义结构对齐的稳定性与一致性。

4.3 实验与分析

4.3.1 实验数据集

为了全面评估 PAMA-SDD 框架在不同数据规模、不同图像分辨率以及细粒度分类任务上的泛化能力，本章选取了三个计算机视觉领域的基准数据集进行实验：CIFAR-100^[89]、ImageNet-1K^[90]以及 CUB-200-2011^[98]。

(1) CIFAR-100：这是一个广泛用于模型分类性能评估的数据集。它包含 60,000 张 32×32 像素的彩色图像，分为 10 个类别，每个类别包 500 张训练图像和 10 张测试图像。由于其图像分辨率低且类别较多，对模型的特征提取能力有较高要求。

(2) ImageNet-1K：这是一个大规模图像分类数据集，包含 1000 个类别，约 128 万张训练图像和 5 万张验证图像。该数据集的规模大、多样性强，能够充分检验蒸馏方法在大规模数据上的泛化能力和实际应用价值。

(3) CUB-200-2011: 这是一个经典的细粒度图像分类数据集, 专门用于鸟类物种识别。它包含 11,788 张图像, 涵盖 200 个鸟类类别, 其中约 5,994 张为训练图像, 5,794 张为测试图像。由于不同鸟类物种间的外观差异极小且背景环境复杂, 该数据集对模型捕捉细微判别性特征的能力提出了严峻挑战。

4.3.2 实验设置

为了确保对比的公平性, 本章的所有实验均基于 MDistiller^[32]知识蒸馏代码库实现。所有基准方法的超参数均严格遵循 MDistiller 的官方基准设置, 未做额外调整。所有在小规模数据集 CIFAR100 和 CUB200 上进行的实验, 均使用一张 Nvidia RTX4090 显卡进行训练, 其拥有 24GB 显存, 所有在大规模数据集 ImageNet 上进行的实验, 均使用两张 Nvidia RTX4090 显卡进行训练, 每张显卡拥有 24GB 显存。所有实验均使用 Ubuntu20.04、Python 3.9 和 Pytorch2.0.0 的环境配置。

网络架构。实验涵盖了多种经典的卷积神经网络架构。教师模型包括 ResNet-32x4、ResNet-50、VGG-13、WRN-40-2 等; 学生模型包括 ResNet-8x4、MobileNet-V2、ShuffleNet-V1/V2、VGG-8 等。这涵盖了同构(架构相似)和异构(架构差异大)的多种组合。

训练参数。对于 CIFAR100 和 CUB200 数据集。所有模型均训练 240 个 epoch, Batch size 设为 64。优化器使用 SGD, 动量为 0.9, 权重衰减为 5×10^{-4} 。初始学习率根据模型类型设为 0.01 (针对 MobileNet/ShuffleNet) 或 0.05 (针对 ResNet/VGG), 并在第 150、180、210 个 epoch 时衰减 0.1 倍。对于 ImageNet 数据集。所有模型均训练 100 个 epoch, Batch size 设 512。优化器使用 SGD, 动量为 0.9, 权重衰减设为 1×10^{-4} 。初始学习率均为 0.2, 并在第 30、60、90 个 epoch 时衰减 0.1 倍。

PAMA-SDD 有三个超参数: 多尺度集合参数 M , 平衡系数 α 和 β 。为了保证实验公平性, 本章将和 SDD 共享完全相同的超参数设置。具体来说, 多尺度集合参数 M 根据不同情况有两种设置: 对于教师模型和学生模型异构的情况, 本章采用 $M = \{1, 2, 4\}$ 进行蒸馏训练; 对于教师模型和学生模型通沟的情况, 本章采用 $M = \{1, 2\}$ 。此外, 针对两个平衡系数 α 和 β , 本章也将其设置为和基准方法(如 KD, DKD, NKD)一致。针对 Warmup 策略, 本章也保持和基准相同的 30 个训练周期预热策略, 以稳定训练初期的多尺度损失。

4.3.3 实验指标

为客观评估各方法在不同数据集上的性能表现, 本章采用分类准确率 (Accuracy) 作为主要评价指标。针对 CIFAR-100 与 CUB-200 等中小规模分类数据集, 本章仅报告 Top-1 Accuracy, 即模型预测概率最高的类别与真实标签一致的样本比例, 用以衡量模型在严格判别条件下的分类能力; 而在 ImageNet 等大规模分类数据集上, 除 Top-1 Accuracy 外, 进一步引入 Top-5 Accuracy,

用于评估模型在多候选预测情形下的类别排序合理性与语义判别稳定性。该指标设置充分考虑了不同数据集在类别数量与语义相似性方面的差异，有助于更加全面、合理地反映不同蒸馏方法在各类实验场景下的性能提升效果。

4.3.4 对比实验

为了验证 PAMA-SDD 的有效性，本章将其与现有的主流知识蒸馏方法进行了对比，包括基于输出特征的方法（KD, DKD, SDD 等）、基于中间特征的方法（FitNet, AT, CRD, OFD, ReviewKD 等）以及基于关系特征的知识蒸馏方法（SP 等），并着重和基线蒸馏方法 SDD 进行了比较。

4.3.4.1 CIFAR100 实验结果及分析

CIFAR-100 数据集包含类别数目多、类别间差异细微的特点，对模型的多尺度判别能力与局部—全局语义建模能力提出了较高要求。表 4.1 与从整体结果可以看出，PAMA-SDD 在不同特征层级配置下均取得了稳定且一致的性能提升，显著优于传统基于全局 logits 的蒸馏方法以及原始尺度解耦蒸馏 SDD，部分组别的学生模型性能甚至超越教师模型。原始 SDD 虽然通过多尺度网格划分缓解了全局 logits 的语义混叠问题，但其不同尺度之间相互独立的蒸馏方式容易导致语义割裂，使局部判别信息缺乏来自其他尺度及全局语义的约束。而 PAMA-SDD 通过渐进式金字塔融合模块 APF，在蒸馏流程前端实现了跨尺度特征的逐级交互，使得不同尺度下的局部特征能够在共享的多尺度语义基座上进行对齐，从而有效提升了尺度一致性。

同时，引入的代理中介注意力模块 AMA 进一步弥补了局部网格划分带来的跨区域依赖缺失问题。通过少量代理令牌对全局语义进行建模，PAMA-SDD 能够在保持线性计算复杂度的前提下，将全局上下文信息引入局部蒸馏过程，使学生模型在学习局部判别线索时始终受到整体语义结构的约束。这一机制对于 CIFAR-100 这类类别细粒度、语义相近的数据集尤为关键。

综上所述，CIFAR-100 实验结果表明，PAMA-SDD 在局部判别增强与全局语义保持之间实现了有效平衡，相较于原始 SDD 与其他对比方法，能够更充分地挖掘多尺度蒸馏的潜力。

表 4.2 给出了在 CIFAR-100 数据集上，不同教师—学生组合及不同蒸馏方法的 Top-1 准确率对比结果。

表 4.1 拥有不同特征层级的教师学生对在 CIFAR100 下 Top-1 准确率（%）

Student	MobileNetV2	VGG8	MobileNetV2	ShuffleNetV1
	64.6	70.36	64.6	70.50
FitNet ^[27]	65.61	70.98	65.12	72.03
SP ^[56]	67.52	73.18	66.34	71.28
CRD ^[92]	69.13	73.88	68.89	75.70
SemCKD ^[99]	68.99	73.67	68.34	75.56

MGD ^[49]	68.13	73.33	68.55	74.99
KD ^[23]	67.72	73.97	68.87	75.82
SD-KD ^[73]	68.84	74.44	69.81	76.87
PAMA-KD	69.75 ^{↑0.91}	75.22 ^{↑0.78}	70.45 ^{↑0.64}	78.29 ^{↑1.42}
DKD ^[32]	68.98	74.13	69.33	77.01
SD-DKD ^[73]	70.08	74.58	70.13	78.11
PAMA-DKD	71.10 ^{↑1.02}	75.00 ^{↑0.42}	71.17 ^{↑1.04}	79.70 ^{↑1.59}
NKD ^[100]	68.81	73.80	68.85	76.22
SD-NKD ^[73]	69.59	74.34	70.04	76.95
PAMA-NKD	70.42 ^{↑0.83}	74.75 ^{↑0.41}	71.49 ^{↑1.45}	78.74 ^{↑1.79}
Teacher	ResNet32x4	WRN40-2	WRN40-2	ResNet50
	79.42	75.61	75.61	79.34

从整体结果可以看出, PAMA-SDD 在不同特征层级配置下均取得了稳定且一致的性能提升, 显著优于传统基于全局 logits 的蒸馏方法以及原始尺度解耦蒸馏 SDD, 部分组别的学生模型性能甚至超越教师模型。原始 SDD 虽然通过多尺度网格划分缓解了全局 logits 的语义混叠问题, 但其不同尺度之间相互独立的蒸馏方式容易导致语义割裂, 使局部判别信息缺乏来自其他尺度及全局语义的约束。而 PAMA-SDD 通过渐进式金字塔融合模块 APF, 在蒸馏流程前端实现了跨尺度特征的逐级交互, 使得不同尺度下的局部特征能够在共享的多尺度语义基座上进行对齐, 从而有效提升了尺度一致性。

同时, 引入的代理中介注意力模块 AMA 进一步弥补了局部网格划分带来的跨区域依赖缺失问题。通过少量代理令牌对全局语义进行建模, PAMA-SDD 能够在保持线性计算复杂度的前提下, 将全局上下文信息引入局部蒸馏过程, 使学生模型在学习局部判别线索时始终受到整体语义结构的约束。这一机制对于 CIFAR-100 这类类别细粒度、语义相近的数据集尤为关键。

综上所述, CIFAR-100 实验结果表明, PAMA-SDD 在局部判别增强与全局语义保持之间实现了有效平衡, 相较于原始 SDD 与其他对比方法, 能够更充分地挖掘多尺度蒸馏的潜力。

表 4.2 拥有相同特征层级的教师学生对在 CIFAR100 下 Top-1 准确率 (%)

Student	ShuNet _{v1}	ShuNet _{v1}	MobNet _{v2}	MobNet _{v2}	ShuNet _{v2}	VGG8
	70.50	70.50	64.6	64.6	71.82	70.36
FitNet ^[27]	73.54	73.73	63.16	63.16	73.54	70.69
RKD ^[28]	72.28	72.21	64.43	64.43	73.21	71.50
SP ^[56]	73.48	74.52	68.08	68.08	74.56	73.34
PKT ^[101]	74.10	72.21	66.52	66.52	74.69	73.01
CRD ^[92]	75.11	76.05	69.11	69.11	75.65	74.30
WcoRD ^[102]	75.77	76.32	70.45	69.47	75.96	74.86
SemCKD ^[99]	76.31	76.06	68.69	69.98	77.02	74.18
ReviewKD ^[54]	77.45	77.14	69.89	70.37	77.78	75.34

卷积神经网络知识蒸馏算法研究

MGD ^[49]	76.22	75.89	68.54	69.44	76.65	73.89
KD ^[23]	74.07	74.83	67.35	67.37	74.45	73.81
SD-KD ^[73]	76.30	76.65	69.55	68.79	76.67	74.89
PAMA-KD	77.63 ^{↑1.33}	77.36 ^{↑0.71}	70.49 ^{↑0.94}	69.70 ^{↑0.91}	76.40	75.29 ^{↑0.40}
DKD ^[32]	76.45	76.70	70.35	69.71	77.07	75.34
SD-DKD ^[73]	77.30	77.21	71.36	70.25	78.05	75.86
PAMA-DKD	79.18 ^{↑1.88}	77.43 ^{↑0.22}	71.80 ^{↑0.44}	71.22 ^{↑0.97}	78.50 ^{↑0.45}	76.45 ^{↑0.59}
NKD ^[100]	75.31	75.96	69.39	68.72	76.26	74.01
SD-NKD ^[73]	76.34	76.81	70.25	69.50	77.07	74.62
PAMA-NKD	76.86 ^{↑0.52}	77.61 ^{↑0.80}	71.48 ^{↑0.23}	70.58 ^{↑1.08}	77.39 ^{↑0.32}	75.03 ^{↑0.41}
Teacher	RN32x4	WRN40-2	RN50	VGG13	RN32x4	RN50
	79.42	75.61	75.61	79.34	79.42	75.61

注：由于表格篇幅原因，ShuNet 表示 ShuffleNet；RN 代表 ResNet；MobNet 代表 MobileNet。

4.3.4.2 ImageNet 实验结果及分析

为进一步验证 PAMA-SDD 在大规模真实场景下的泛化能力，本章在 ImageNet 数据集上对 SDD 和 PAMA-SDD 方法进行了系统评估，实验结果如表 4.3 所示，报告了 Top-1 与 Top-5 准确率。

表 4.3 ImageNet 数据集上的 Top-1 和 Top-5 准确率（%）

Student	ResNet18	MobileNet
	69.75/89.07	68.87/88.76
KD ^[23]	70.66/89.88	70.50/90.34
SD-KD ^[73]	71.44/90.05	72.24/90.71
PAMA-KD	71.66 ^{↑0.22} /90.48 ^{↑0.43}	72.69 ^{↑0.45} /91.27 ^{↑0.56}
DKD ^[32]	71.70/90.41	72.05/91.05
SD-DKD ^[73]	72.02/91.21	73.08/91.09
PAMA-DKD	72.35 ^{↑0.33} /91.74 ^{↑0.53}	73.60 ^{↑0.52} /91.83 ^{↑0.74}
NKD ^[100]	71.96/91.10	73.08/91.09
SD-NKD ^[73]	72.33/91.31	73.12/91.11
PAMA-NKD	72.57 ^{↑0.24} /91.42 ^{↑0.11}	73.44 ^{↑0.32} /91.73 ^{↑0.62}
Teacher	ResNet34	ResNet50
	73.31/91.42	76.16/92.86

与 CIFAR-100 上的实验结论一致，PAMA-SDD 在 ImageNet 数据集上同样取得了稳定的性能提升，在 Top-1 与 Top-5 指标上均优于 SDD。这表明所提出的方法并未过度依赖小规模数据集中的类别分布特性，而是在更复杂、多样化的视觉场景中依然具备良好的泛化能力。

值得注意的是, ImageNet 数据集中目标尺度变化更加显著、背景更加复杂, 这对模型的全局上下文建模能力提出了更高要求。在这种情况下, 单纯依赖局部网格蒸馏容易放大局部显著区域的影响, 而忽略物体整体结构信息, 从而影响最终分类决策。PAMA-SDD 通过代理中介注意力机制显式建模跨区域的长距离语义依赖, 使得局部尺度上的判别学习能够受到全局语义一致性的引导, 从而有效缓解了由局部最优引发的整体误判问题。此外, 渐进式金字塔融合模块在 ImageNet 场景中同样发挥了关键作用。通过平滑的跨层融合路径, 不同层级特征之间的语义鸿沟得以缓解, 使深层语义信息能够反向指导浅层特征的判别学习, 从而提升了多尺度蒸馏过程的稳定性。

4.3.4.3 CUB200 实验结果及分析

针对细粒度图像分类任务对局部特征判别力与全局结构感知的双重高要求, 本章在 CUB-200-2011 鸟类数据集上进行了深入的性能评估。该任务的挑战在于不同子类(如不同种类的麻雀)之间仅存在极其细微的局部差异(如喙的形状、羽毛纹理), 且往往受姿态变化和背景遮挡的影响。

表 4.4 CUB200 数据集上的 Top-1 准确率 (%)

Student	MobileNetV2	ShuffleNetV1	MobileNetV2	VGG8	ShuffleNetV1
	40.23	37.28	40.23	46.32	37.28
SP ^[54]	48.49	61.83	44.28	54.78	55.31
CRD ^[92]	57.45	62.28	56.45	66.10	57.45
SemCKD ^[99]	56.89	63.78	68.23	66.54	57.20
ReviewKD ^[54]	-	64.12	58.66	67.10	-
MGD ^[49]	-	-	-	66.89	57.12
KD ^[23]	56.09	61.68	53.98	64.18	57.21
SD-KD ^[73]	60.51	65.46	59.80	67.32	60.56
PAMA-KD	63.62 ^{†3.11}	66.14 ^{†0.68}	61.98 ^{†2.18}	68.57 ^{†1.25}	61.13 ^{†0.57}
DKD ^[32]	59.94	64.51	58.45	67.20	59.21
SD-DKD ^[73]	62.97	65.58	64.86	68.67	60.66
PAMA-DKD	64.38 ^{†1.41}	67.05 ^{†1.47}	67.52 ^{†2.66}	68.81 ^{†0.14}	62.50 ^{†1.84}
NKD ^[100]	59.81	64.00	58.40	67.16	59.11
SD-NKD ^[73]	62.69	65.50	64.63	68.37	60.42
PAMA-NKD	66.69 ^{†4.00}	67.00 ^{†1.50}	69.09 ^{†4.46}	69.23 ^{†0.86}	62.43 ^{†2.01}
Teacher	ResNet32x4	ResNet32x4	VGG13	VGG-13	ResNet50
	66.17	66.17	70.19	70.19	60.01

实验结果表明, PAMA-SDD 在此类细粒度任务中展现出了惊人的性能提升, 如表 4.4 所示,

在三个经典知识蒸馏算法上进行 PAMA-SDD 的集成后,相较于集成 SDD 后蒸馏得到的学生模型,性能均有大幅提升,在部分实验组中,学生模型的性能甚至超过了教师模型的性能,相较于基础蒸馏算法性能提升幅度高达将近 10%。

在 CUB-200-2011 细粒度数据集上, PAMA-SDD 之所以能取得如此显著的性能增益,根本原因在于其核心机制完美契合了细粒度分类任务对“局部辨识度”与“全局结构性”的双重需求。细粒度分类的难点在于区分极其相似的子类,这不仅依赖于对鸟喙、羽毛纹理等微小局部特征的精准捕捉,更需要理解这些局部部件如何组合成一个完整的语义整体。传统的尺度解耦蒸馏虽然通过网格划分强化了局部特征的提取,但这种物理切割往往破坏了鸟类身体各部位(如头部与躯干)之间的内在语义联系,导致模型“见木不见林”,在面对遮挡或姿态变化时极易误判。相比之下, PAMA-SDD 引入的代理中介注意力模块 AMA 恰好弥补了这一结构性缺陷,它通过引入全局代理令牌,在解耦的局部网格之间重新建立了长距离依赖,相当于为破碎的局部特征注入了全局上下文的“粘合剂”。这种机制使得轻量级学生模型在关注微小差异的同时,能够像教师网络一样保持对物体整体形态的连贯认知。此外,渐进式金字塔融合 APF 进一步确保了浅层纹理细节与深层语义信息的有效对齐,这种多尺度的特征增强对于区分外观高度相似的鸟类至关重要。因此, PAMA-SDD 在细粒度任务上的优异表现,本质上是因为它成功解决了局部特征解耦与全局语义重构之间的矛盾,从而实现了超越传统方法的知识迁移效率。

4.3.5 消融实验与深入分析

4.3.5.1 消融实验

为系统分析本章提出的 PAMA-SDD 各组成模块在细粒度知识蒸馏任务中的作用机制,本章在 CUB-200-2011 数据集上,基于 VGG13→MobileNetV2 的师生结构配置,对 APF、AMA 以及 GAC Loss 进行逐项消融实验,实验结果汇总于表 4.5。

表 4.5 PAMA-SDD 在 CUB200 数据集上各模块消融实验结果

模块	APF	AMA	GAC Loss	Top-1 Acc	$\uparrow \Delta$
Baseline(SD-KD)				64.86	0
Baseline+APF	✓			65.89	1.03
Baseline+AMA		✓		66.37	1.51
Baseline+APF+AMA	✓	✓		67.09	2.23
PAMA-SDD	✓	✓	✓	67.52	2.98

注: 选取 VGG13 和 MobileNetV2 作为教师学生对。

在不引入任何改进模块的情况下,基线方法 Baseline(SDD-DKD)在该设置下取得 64.86%的 Top-1 分类准确率。该结果反映了基于尺度解耦蒸馏的特征对齐策略在细粒度场景中的基本性能水平,但同时也暴露出由于机械空间划分导致的语义连续性受损问题。

在此基础上, 仅引入渐进式金字塔融合模块 APF 后, 模型性能提升至 65.89%, 相较基线获得 1.03% 的稳定增益。该结果表明, 通过自顶向下的多尺度特征融合路径, APF 能够在不显著增加模型复杂度的前提下, 构建更加平滑、层级一致的语义表征基座, 从而为后续知识对齐提供更适合蒸馏的特征分布。

当仅引入代理中介注意力模块 AMA 时, 模型准确率进一步提升至 66.37%, 相对基线提高 1.51%。与 APF 相比, AMA 带来的增益更为显著, 这说明在 CUB-200 这类高度依赖局部部件关系与整体形态组合的细粒度任务中, 跨区域的全局上下文建模能力是影响蒸馏效果的关键因素之一。AMA 通过代理令牌在不同空间网格之间建立高效的信息交互路径, 有效缓解了尺度解耦策略中由局部对齐引入的长距离依赖断裂问题。

进一步地, 当 APF 与 AMA 同时启用时, 模型性能达到 67.09%, 相较基线整体提升 2.23%。该结果验证了两种机制之间的显著互补性: APF 提供语义连续、尺度一致的特征基座, 而 AMA 在此基础上重建跨尺度、跨区域的全局结构关联, 使学生模型在保留细粒度判别能力的同时, 获得更完整的语义组织方式。

最后, 在同时启用 APF 和 AMA 的基础上进一步引入全局代理一致性损失 GAC Loss 后, 得到完整的 PAMA-SDD 模型, 其 Top-1 准确率提升至 67.52%。相较前者, 性能提升 0.43%, 相对基线的总提升达到 2.66%。尽管该增益幅度相对温和, 但其作用具有明确的结构意义: GAC Loss 在代理语义层面对师生特征施加显式一致性约束, 有效抑制了仅依赖局部或中尺度优化可能引入的全局语义偏移, 通常体现为训练后期性能上限的稳定抬升以及蒸馏过程的整体稳定性增强。

综合表 4.5 的消融结果可以看出, 类间相关性分析

为进一步不同蒸馏方法对特征判别结构的影响, 本章对传统知识蒸馏与所提出的 PAMA-SDD 方法在测试集上的高维特征进行了 t-SNE 可视化, 如图 4.6 所示。图中不同颜色表示不同类别样本, 点之间的相对距离反映了特征空间中的相似性关系。




图 4.6 KD（左）和 PAMA-KD（右）训练得到的学生模型 t-SNE 可视化图

从左侧传统 KD 的可视化结果可以观察到，尽管部分类别已形成初步的聚类结构，但整体分布仍呈现出较为明显的类间交叠现象。一些语义相近的类别在特征空间中相互混杂，类内样本分布较为分散，类间边界不够清晰。这表明传统 KD 在蒸馏过程中主要依赖全局输出或局部响应对齐，虽然能够传递一定的判别信息，但在复杂语义结构和多尺度特征建模方面仍存在不足，导致学生模型难以形成紧凑且具有良好分离性的特征表示。

相比之下，右侧 PAMA-SDD 的 t-SNE 分布呈现出更加清晰的聚类结构。可以看到，不同类别样本在特征空间中的分布更加紧凑，类内一致性显著增强，同时类间间隔更加明显，整体判别边界更加清晰。特别是在语义相近或背景复杂的类别之间，PAMA-SDD 能够有效减少特征混叠现象，使样本在高维空间中形成更加稳定且结构化的分布。

上述现象与 PAMA-SDD 的设计初衷高度一致。一方面，渐进式金字塔融合模块通过平滑的跨层特征融合，为蒸馏过程提供了语义一致的多尺度特征基座，有助于学生模型在不同尺度下形成协调一致的判别表示；另一方面，代理中介注意力机制及其全局一致性约束显式建模了跨区域的长距离依赖关系，使局部判别学习始终受到全局语义结构的引导，从而有效缓解了尺度解耦蒸馏中可能引入的语义割裂问题。最终，这种“局部判别增强与全局语义保持”的协同优化，使得学生模型在特征空间中呈现出更加清晰且具有判别性的聚类结构，从可视化角度进一步验证了 PAMA-SDD 在提升特征表达质量方面的有效性。

4.3.5.2 注意力图可视化分析

注意力可视化用于直观反映模型在推理过程中对输入图像不同空间区域的关注程度，从而揭示其判别决策所依赖的关键区域。通过分析注意力分布是否集中于目标主体及其语义关键部

位，可以评估模型的语义建模能力及其对背景干扰的鲁棒性。为进一步分析 PAMA-SDD 蒸馏框架的有效性，本章对在 CUB200 数据集上分别在 SDD 和 PAMA-SDD 蒸馏框架下，以 VGG13 作为教师模型蒸馏得到的 MobileNetV2 模型进行推理，得到如图 4.7 所示的注意力可视化结果。

从结果可以观察到，SDD-KD 虽然在一定程度上能够引导学生模型关注目标主体，但其注意力分布仍呈现出较为明显的离散性和局部偏置，部分响应集中于背景纹理或目标的局部高对比区域，导致对目标整体语义结构的刻画不够完整。相比之下，PAMA-SDD-KD 的注意力响应更加集中且连续，能够稳定覆盖鸟类的关键判别区域，并显著抑制背景干扰信息。这一改进主要得益于 AMA 模块在蒸馏过程中引入的代理中介注意力机制：通过少量代理令牌显式建模跨区域的长距离语义依赖，使局部特征的注意力分配始终受到全局语义的引导与约束，从而避免尺度解耦蒸馏中常见的注意力碎片化问题。注意力可视化结果从直观层面验证了 PAMA-SDD-KD 在恢复全局语义一致性、提升细粒度目标感知能力方面的有效性。




图 4.7 SDD 和 PAMA-SDD 蒸馏得到学生模型在 CUB200 数据集上推理得到的注意力图

4.4 小结

本章针对现有尺度解耦蒸馏 SDD 方法中存在的特征尺度单一、机械网格划分导致语义割裂以及全局上下文信息丢失等核心问题，提出了一种基于金字塔与代理中介注意力的增强型蒸馏框架 PAMA-SDD。

首先，本章详细阐述了渐进式金字塔融合模块 APF 的构建原理。针对深浅层特征间的语义鸿沟，APF 通过自顶向下的平滑路径与自适应空间融合机制，构建了高质量的多尺度特征基座，使得模型能够在不同分辨率下进行一致性的语义对齐，有效克服了传统 SDD 视野受限的缺陷。

其次，本章引入了代理中介注意力模块 AMA 与全局代理一致性损失 GAC Loss。针对 SDD 物理切割导致的像素间长距离依赖断裂问题，AMA 利用线性复杂度的代理令牌重构了全局上下文，而 GAC Loss 则进一步显式约束了师生网络在“语义原型”层面的一致性。这种机制确保了学生模型在进行局部细粒度解耦蒸馏的同时，始终保持对全局场景的完整感知。

最后，在 CIFAR-100、ImageNet-1K 及细粒度数据集 CUB-200-2011 上的广泛实验结果表明，PAMA-SDD 在同构及异构网络设置下均取得了优于现有主流方法的性能。特别是在细粒度分类任务中，该方法展现了卓越的特征捕捉能力，验证了多尺度融合与全局上下文注入对于提升蒸馏效率的必要性与有效性。